

人体运动状态识别解决方案

1. 特征提取

由于加速度计和陀螺仪采集的人体运动的 6 维原始数据，企图有效地描述和区分不同的运动状态是不可行的。那么，结合现实生活中的先验知识，对采集的时间序列数据加以有效处理并建立合理的模型是比较可取的途径。

为了与给定数据格式保持一致，记受试者 $S_i(i = 1, \dots, 14)$ 的第 j 个运动状态为 A_{ij} ，其由 T 个时刻的 6 维采集数据构成，即

$$A_{ij} = \begin{bmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_T \end{bmatrix} = [X_1 \quad \dots \quad X_6]$$

其中， $Y_t = [\text{acc}_x, \text{acc}_y, \text{acc}_z, \text{gyro}_x, \text{gyro}_y, \text{gyro}_z]$ 为时刻 t 该动作的原始数据，分别对应 x 轴、 y 轴、 z 轴方向的加速度和角速度，规定竖直向下为 x 轴正方向，前进方向为 y 轴正方向，水平向右为 z 轴正方向，且 x 轴垂直于 y 轴和 z 轴组成的平面； $X_1 \sim X_6$ 分别对应该运动下 6 个维度的时间序列，记某维度的时间序列为

$$X = [x_1 \quad \dots \quad x_T]^T$$

由受试者 Subject1 的 walking-forward 运动的时序数据，得到其三轴加速度的波形图、直方图以及频谱图，如图 1 所示。

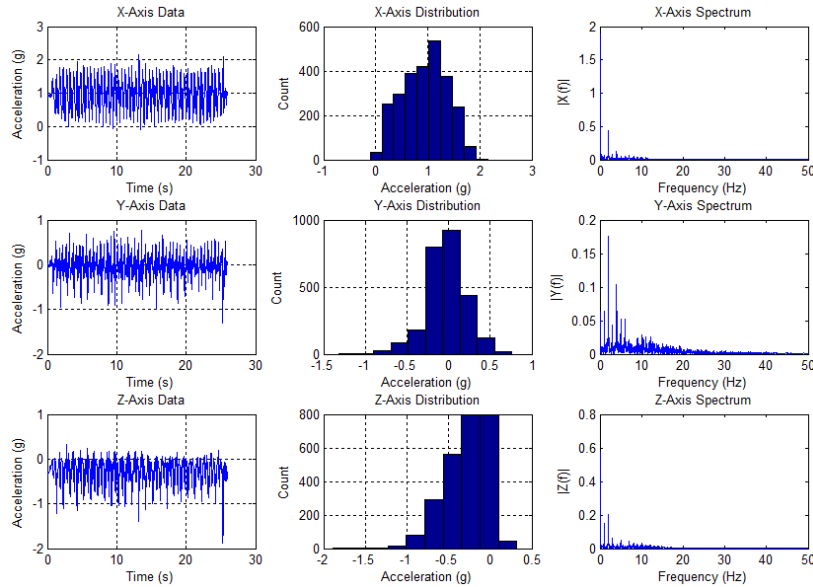


图 1. 受试者 Subject1 的 walking-forward 状态的三轴加速度的波形、直方图和频谱图

由图 1 的波形图可见信号呈现周期性变化，但是因身体晃动、噪声等其他因素使得信号夹杂着噪声，抖动明显，于是，原始数据的预处理对识别效果至关重要。波形的尖峰毛刺是信号中混杂的高频噪声，这里，采用截止频率为 10Hz 的 5 阶巴特沃斯低通滤波器对原始数据进行降噪处理。

再根据数理统计的知识和相关经验，对运动 A_{ij} 提取区分性好的统计量和物理量，具体包括，

(1) 时间序列 X 的均值

$$\mu = \frac{1}{T} \sum_{i=1}^T x_i$$

(2) 时间序列 X 的标准差

$$\sigma = \sqrt{\frac{1}{T} \sum_{i=1}^T (x_i - \mu)^2}$$

(3) 时间序列 X 的方差

$$\sigma^2 = \frac{1}{T} \sum_{i=1}^T (x_i - \mu)^2$$

方差是标准差的平方，二者均反映的是数据的波动和分布范围，方差（或标准差）小的波动范围小，方差（或标准差）大的分布越广。结合实际，从加速度大小的角度知，标准差、方差两个统计量可以很好的区分走、跑、跳等剧烈程度不同的动作。

(4) 时间序列 X 的中值

$$m = \frac{1}{2} (x_{\frac{n}{2}} + x_{\frac{n}{2}+1})$$

中值可以有效避免极值数据的影响，并没有利用全部数据，但其存在的意义，通常与均值、方差和标准差字段结合使用。

(5) 三轴加速度的矢量和在 T 时间段的均值

$$AI = \frac{1}{T} \sum_{t=1}^T MI(t) = \frac{1}{T} \sum_{t=1}^T \sqrt{acc_x(t)^2 + acc_y(t)^2 + acc_z(t)^2}$$

(6) 三轴加速度的矢量和在 T 时间段的方差

$$VI = \frac{1}{T} \sum_{t=1}^T (MI(t) - AI)^2$$

(7) 三轴加速度信号幅值

$$SMA = \frac{1}{T} \left(\sum_{t=1}^T |acc_x(t)| + \sum_{t=1}^T |acc_y(t)| + \sum_{t=1}^T |acc_z(t)| \right)$$

AI、VI和SMA是基于三轴加速度的物理统计量，均值和方差能够很好的反映不同运动的合加速度，幅值能反映运动能量的大小。

(8) 时间序列 X 的峰度

$$\beta = \frac{\sum_{i=1}^n (x_i - \mu)^4}{(n-1)\sigma^4}$$

峰度表征概率密度分布曲线在平均值处峰值高低的特征数，直观上反映密度函数曲线尾部的厚度，或者可以认为反映分布形态的陡缓程度，可以很好地描述运动的不同

形态。

(9) 时间序列 X 的偏度

$$\alpha = \frac{\sum_{i=1}^n (x_i - \mu)^3}{n\sigma^3}$$

偏度可以度量统计数据的分布偏斜方向和程度，描述数据分布的非对称程度，结合分布直方图，可以很好地描述不同的运动分布。

(10) 时间序列 X 的 25 百分位点 Q_1

(11) 时间序列 X 的 75 百分位点 Q_3

统计学上，将一组数据从大到小排序，并计算相应的累计百分位，则某一百分位所对应数据的值就称为这一百分位的百分位数。25 百分位数 Q_1 是第一个四分位数，75 百分位数 Q_3 是第三个四分位数。

(12) 时间序列 X 的四分位差 $Q = Q_3 - Q_1$

(13) 任意两维数据序列的相关系数

$$r_{ij} = \frac{\sum_{t=1}^T (x_t - \mu_i)(y_t - \mu_j)}{\sqrt{\sum_{t=1}^T (x_t - \mu_i)^2 \sum_{t=1}^T (y_t - \mu_j)^2}}$$

相关系数表征两维数据的关系密切程度，直观上，可以有效区分二维和三维运动。

(14) x 轴加速度在 $[x_1, x_{\frac{T}{2}}]$ 时间段内的均值

(15) x 轴加速度在 $[x_{\frac{T}{2}}, x_T]$ 时间段内的均值

(16) x 轴加速度在 $[x_1, x_{\frac{T}{2}}]$ 时间段内的最大值

(17) x 轴加速度在 $[x_{\frac{T}{2}}, x_T]$ 时间段内的最小值

基于乘电梯上下楼运动的失重、超重现象，竖直方向的加速度在波形图上呈现不同的凹凸形状，从理论上讲，统计量(13)、(14)、(15)和(16)可以区分 elevator-up 和 elevator-dawn 两个运动。

2. 特征筛选

每个维度的上述统计特征都是合理的、可区分的，可能存在冗余的特征，甚至干扰的特征，需要进一步分析和筛选，从而达到更好的分类识别效果。这里，我们并没有用到主成份分析、因子分析这样的方法进行特征的降维，主要考虑这两种方法不能实现特征的筛选，主成份分析法是从已有的特征中抽取融合出新的特征，而因子分析法则提取多变量的公共因子。于是，我们通过将特征应用到 12 个状态，图表显示来考量该特征对 12 个特征的区分度从而剔除区分度小的特征保留区分度大的特征。

首先，对原始数据采用截止频率为 10Hz 的 5 阶巴特沃斯低通滤波器对原始数据进行降噪处理，原始序列信号及滤波后信号如图 2 所示。




图 2. 原始信号序列及滤波后信号波形图

由图 2 可知，滤波后数据的尖峰毛刺得到有效的去除，使得后续的分类识别准确率得以提高。

建模过程提到的所有特征并不都是有用的，有些可能是 12 个动作所共有的特征，这些特征在识别分类方面往往效果不佳，反而会影响最终的识别结果。于是，通过考量上述每个特征的可分性，最后选择以下共 61 维特征，如表 1 所示。

表 1. 筛选得到的 57 维特征

编号	特征内容	编号	特征内容
fac1、2	序列 X_1 、 X_4 的均值	fac20	序列 X_1 的偏度
fac3、4to6	序列 X_1 、 $X_4 \sim X_6$ 的均方差	fac21to26	序列 $X_1 \sim X_6$ 的四分位差
fac7、8to10	序列 X_1 、 $X_4 \sim X_6$ 的方差	fac27to32	序列 $X_1 \sim X_6$ 的 25 分位点
fac11to12	序列 X_1 、 X_4 的中值	fac33to47	序列 $X_1 \sim X_6$ 两两间的相关系数
fac13、14	三轴加速度的矢量和的均值、方差	fac48to53	序列 $X_1 \sim X_6$ 的 75 分位点
fac15	三轴加速度信号的幅值	fac54、55	序列 X_1 前半段、后半段的均值
fac16to19	序列 $X_1 \sim X_4$ 、 $X_4 \sim X_5$ 的峰度	fac56to61	序列 $X_1 \sim X_6$ 的加窗均值特征

以序列均值为例，图 3 表示序列 $X_1 \sim X_6$ 的均值特征。




图 3. Subject1 的 12 种状态序列 $X_1 \sim X_6$ 的均值特征

由图 3 可知，序列 X_1 的均值能够将状态 $A_{1,10}$ 与其他状态明显区分开，从物理意义上，状态 $A_{1,10}$ 为 sleeping，那么竖直方向的加速度可以认为恒定为某一个常数，于是，竖直加速度的均值自然稳定在常数值位置；另外，序列 X_4 的均值分布在区间 $[-50,50]$ ，而且不同状态的分布位置不同，也能够有效地对不同状态加以区分。然而，其余序列的均值分布区间小，且分布集中，不是有效的分离指标。

这正是剔除序列 $X_2 \sim X_3$ 、 $X_5 \sim X_6$ 的均值特征，而保留 X_1 、 X_4 的均值的原因。其余特征的剔除和保留也是通过该方法实现。

为了分析模型与数据的一致性，需要考察所有特征的实际意义，具体而言，根据特征的区别性判别不同特征取值是否能表示不同的状态。




图 4. 序列 X_1 的均值特征

图 4 为受试者 Subject1 的 5 个状态的 5 次序列 X_1 的均值分布，可见该特征能够有效区分 sleeping 和其他运动状态，数据本身的物理特征符合序列均值模型。

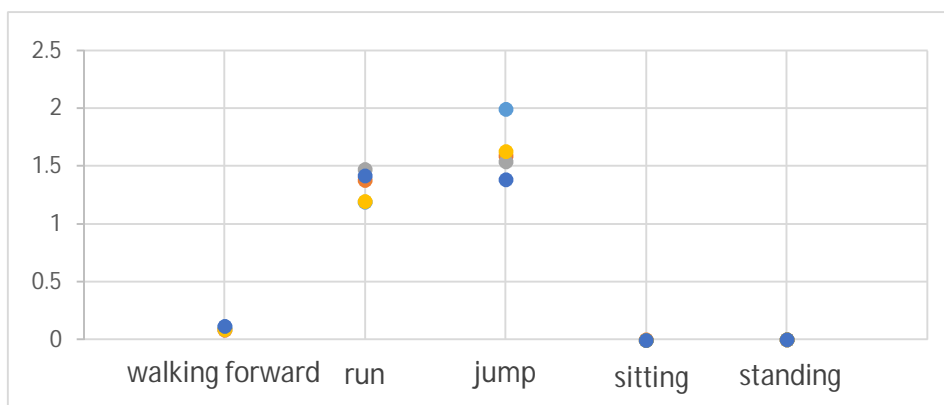


图 5. 序列 X_1 的方差特征

图 5 为受试者 Subject1 的 5 个状态的 5 次序列 X_2 的方差分布，方差反映数据的波动范围，图中状态 run 和 jump 的幅度相对其他状态变化最大，正好解释实际中沿着前进方向的加速度变化大小，即跑步和跳跃应该是加速度波动最大的，所以，沿着运动方向的加速度方差模型与数据蕴含的信息是一致的。




图 6. 序列 X_4 的中值特征

对于步行状态，仅采用加速计采集的加速度信号似乎并不能实现向左走、向右走和沿着直线向前走的区分，图 6 显示受试者 Subject1 的这三个状态的 5 次 X_4 序列的中值分布，可见中值的大小有效地区分这三个状态动作，故 x 轴角速度模型与原始数据的分布特征是一致的。




图 7. 序列 X_1 的峰度特征

图 7 中，状态 7—10 分别为 sitting、standing、sleeping 为静态动作，时间序列上数据变化稳定且分布集中，故其直方图分布相对于其余的状态，能够看到明显的尖峰，于是，峰度值具有可分性，且峰度模型与原始数据特征是一致的。




图 8. 序列 X_1 的偏度特征

偏度同样是反映数据的统计直方图的特征的,图 8 显示偏度也能有效将 sitting、standing、sleeping 三个运动状态与其余区分开,故偏度模型与数据是一致的。

上述特征对于乘电梯上下楼而言并不具有可分性,于是由二者所呈现的超重失重现象导致的竖直方向加速度的变化生成新的特征,其区分效果如图 9 所示。

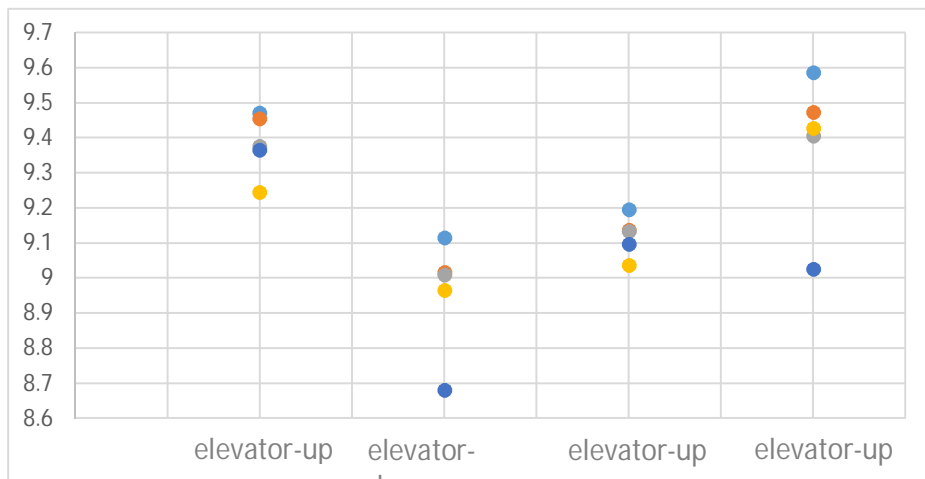


图 9. 序列 X_1 的前半段均值、后半段均值特征

从图 9 可知,数据序列的前半段均值、后半段均值有效地区分 elevator-up、elevator-down 两个状态,且乘电梯上楼在前半段的超重使得其波形图有明显的凸起,后半段因失重使得波形图有明显的下凹,乘电梯下楼正好相反,二者波形图如图 10 所示。




图 10. 受试者 Subject1 的状态 elevator-up、elevator-down 的波形图

综上所述,刻画各运动状态的关键因素是 x 轴加速度、y 轴加速度、x 轴角速度,其中,影响状态 walking-forward、walking-left、walking-right 的关键指标是 x 轴加速度、y 轴加速度和

x 轴角速度，影响其他状态的最主要的指标是 x 轴加速度。另外，从提取并筛选的特征角度看，刻画各运动状态的关键指标如表 2 所示。

表 2. 刻画各运动状态的关键指标

运动状态	关键指标
walking-forward	fac1、fac2、fac3、fac7
walking-left	fac1、fac2、fac8
walking-right	fac1、fac2、fac8
walking-upstairs	fac1、fac2、fac3、fac7
walking-downstairs	fac1、fac2、fac3、fac7
run	fac1、fac7、fac11、fac21-fac53、fac56-fac61
jump	fac1、fac7、fac11、fac21-fac53
sitting	fac1、fac3、fac7、fac13、fac14、fac15、fac19、fac20
standing	fac1、fac3、fac7、fac13、fac14、fac15、fac19、fac20
Sleeping	fac1、fac3、fac7、fac19、fac20
elevator-up	fac1、fac54-fac55
elevator-down	fac1、fac54-fac55

61 维特征数据依然存在大量的冗余信息，为了降低算法复杂度，提高模型精确度，在应用分类算法之前还应利用降维算法去除冗余的特征信息。减少特征个数，防止维数灾难，并且可以加快程序的运行速度。本文运用的特征降维方法是 LDA 算法。

线性判别式分析 (Linear Discriminant Analysis, LDA)，也叫做 Fisher 线性判别 (Fisher Linear Discriminant, FLD)。线性判别分析的基本思想是将高维的模式样本投影到最佳鉴别矢量空间，以达到抽取分类信息和压缩特征空间维数的效果，投影后保证模式样本在新的子空间有最大的类间距离和最小的类内距离，即模式在该空间中有最佳的可分离性。因此，它是一种有效的特征抽取方法。使用这种方法能够使投影后模式样本的类间散布矩阵最大，并且同时类内散布矩阵最小。就是说，它能够保证投影后模式样本在新的空间中有最小的类内距离和最大的类间距离，即模式在该空间中有最佳的可分离性。该算法利用分析类间离散度矩阵与类内离散度矩阵，所要刻画的坐标轴当然要使得类内各个样本鱼类之间的离散度小即类内离散度矩阵的数值要小，而类间的耦合度低即类间离散度矩阵的数值要大，这样分类的效果才好。

由于 LDA 是线性分类的，所以要推广到多类的问题，常用的方法是用 one-vs-all 方式训练 K 个分类器，以及任意两个分类配对训练分离器最后得到针对 $k(k-1)/2$ 个的二类分类分析器。这里，LDA 方法 onevsall 多分类使得 61 维降低到 30 维。

3. 分类识别

常见的分类器有 k 近邻分类算法 (kNN)、支持向量机 (SVM)、基于决策树的随机森林算法等。本文将综合考虑三种分类器，根据各自的识别准确率及多数优先原则，给出未知类别的最终分类结果。

• k 近邻分类算法

k 近邻分类算法是一款成熟的数据挖掘算法，其基本思想是采用未知事物与已知事物之间的欧式距离作为相似度度量准则，距离越小，二者相似度越大。简单讲就是从训练样本中找出 K 个与其最相近的样本，然后看这 K 个样本中哪个类别的样本多，则待判定的值就属于这个类别。

具体步骤如下：

- 1) 计算已知类别数据集中每个点与当前点的距离;
- 2) 选取与当前点距离最小的 K 个点;
- 3) 统计前 K 个点中每个类别的样本出现的频率;
- 4) 返回前 K 个点出现频率最高的类别作为当前点的预测分类。

• 支持向量机

支持向量机是一种有监督的学习算法，可以分析数据，识别模式，用于分类和回归分析。在解决小样本、非线性及高维模式识别中表现出许多特有的优势，并能够推广应用到函数拟合等其他机器学习问题中。具体算法为先将样本标准化，分为训练样本与测试样本，再将距离矩阵变为核矩阵的形式，本文采用拉普拉斯核函数作为核函数，采用onevsone的方法进行多分类，每次SVM的计算采用SMO优化算法进行迭代，最后分类时对测试样本进行SVM预测，算出每一个样本对所有二分类分类器的分类情况做排序，分类的类别最多的则将该样本分为此类。这里，准确率的定义为预测正确的样本数量同总数量的比值。

• 基于决策树的随机森林算法

随机森林是用随机的方式建立一个森林，森林里面有很多的决策树组成，决策树之间是没有关联的。在得到森林之后，当有一个新的输入样本进入的时候，就让森林中的每一棵决策树分别进行一下判断，看看这个样本应该属于哪一类，然后看看哪一类被选择最多，就预测这个样本为那一类。

基于决策树的随机森林算法是一种组合分类器，本身基于决策树算法。 $tree_1$ 、 $tree_2$ 、 \dots 、 $tree_B$ 是随机产生的彼此没有关联的B棵决策树，将他们组合在一起形成一个随机森林。当新样本X到来时，对各决策树产生的分类结果 k_1 、 k_2 、 \dots 、 k_B 进行投票，得票最多的分类结果当选为新样本x的类别。

• BP神经网络分类器的设计

在神经网络中，当神经元接收到其他神经元传递过来的输入信号，这些输入信号通过带权重的连接进行传递，神经元接收到的总输入值将与神经元的阈值进行比较，然后通过“激活函数”处理以产生神经元的输出。其中，网络的训练过程体现人工神经网络的自学习和自适应的能力，通过预先提供的一批相互对应的输入-输出数据，采用动态调整误差的方式学习二者间的潜在规律，并预测输入样本的所属类别。BP神经网络的基本原理包括，

• 神经元模型




图 12. 神经元模型

每个神经元中，R个输入信号通过与权值矩阵求加权和，作为净输入送入传输函数，图12中的传输函数为硬极限函数，输出为1或-1。

• 网络结构

BP神经网络是基于误差反向传播算法的多层前馈网络，其学习规则为梯度下

降法，通过反向传播不断调整网络的权值和偏置，使网络的误差平方和最小。该网络的拓扑结构包括输入层、隐含层和输出层。




图 111. Bp 神经网络的网络结构

其中，隐含层的传输函数为 sigmoid 函数，即对于输入样本

$$X = [x_1 \quad \cdots \quad x_n]^T$$

隐含层第 j 个神经元的净输入为

$$hi_j = \sum_{i=1}^n w1_{ij} \cdot x_i$$

隐含层第 j 个神经元的输出为

$$ho_j = f(hi_j) = \frac{1}{1 + e^{-hi_j}}.$$

而输出层的传输函数为线性函数 (purelin 函数)，以隐含层的输出作为输出层的输入，则输出层的第 k 个神经元的净输入为，

$$yi_k = \sum_{j=1}^m w2_{jk} \cdot ho_j$$

由线性函数性质知，输出层第 k 个神经元的输出即为其净输入值，

$$yo_k = f(yi_k) = yi_k.$$

- 学习规则

梯度下降法修正误差，是要寻找权值使得网络输出的均方误差最小，即

$$\min J(W^m, b^m) = \min E[e^T e] = \min E[(d - a)^T (d - a)]$$

其中， d 为期望输出， a 为实际输出。采用瞬时平方误差近似计算均方误差，有，

$$\hat{J}(W^m, b^m) = e(k)^T e(k) = (d(k) - a(k))^T (d(k) - a(k))$$

则沿着梯度反方向的最速下降法为

$$\begin{cases} w_{ij}^m(k+1) = w_{ij}^m(k) - \alpha \Delta w_{ij}^m = w_{ij}^m(k) - \alpha \frac{\partial \hat{J}}{\partial w_{ij}^m} \\ b_i^m(k+1) = b_i^m(k) - \alpha \Delta b_i^m = b_i^m(k) - \alpha \frac{\partial \hat{J}}{\partial b_i^m} \end{cases}.$$

- 实现步骤

BP 神经网络分类算法分为训练阶段和测试阶段，其中，训练阶段的具体步骤如下，

- (1) 前向传播——计算隐含层和输出层的输出
- (2) 反向传播——计算各层的灵敏度

输出层的灵敏度为

$$\Delta w_{jk}^m = (y_{0k} - \widehat{y_k})^T * h_{0j}$$
$$\Delta b_k^m = (y_{0k} - \widehat{y_k})^T$$

隐含层灵敏度为

$$\Delta w_{ij}^m = h_{0j}(1 - h_{0j})x_{ij} \sum_{j=1}^l w_{jk}^m (y_{0k} - \widehat{y_k})^T$$
$$\Delta b_j^m = h_{0j}(1 - h_{0j}) \sum_{j=1}^l w_{jk}^m (y_{0k} - \widehat{y_k})^T$$

(3) 权值调整

$$w_{ij}^m(k + 1) = w_{ij}^m(k) + \alpha \Delta w_{ij}^m$$
$$b_j^m(k + 1) = b_j^m(k) + \alpha \Delta b_j^m$$
$$w_{jk}^m(k + 1) = w_{jk}^m(k) + \alpha \Delta w_{jk}^m$$
$$b_k^m(k + 1) = b_k^m(k) + \alpha \Delta b_k^m$$

训练结束后，得到最终的权值矩阵和偏置值。对于测试数据集，只需将每一个测试样本的特征数据送入识别系统，即可得到测试数据的预测输出结果。

以给定数据中14名受试者的12名受试者的前3时刻的数据构成训练集，其余两个时刻的数据构成测试数据，LDA方法onevsall多分类使得61维降低到30维，训练过程中，统计得到SVM、KNN、随机森林分类器、BP神经网络分类器的识别准确率分别为70.24%、67%、77.38%、85%（最好的情况），于是，对unknow数据集的未知的20组数据进行判别分析，得到四种分类器的识别结果，如表3所示。

表 3. 四种分类器的识别结果

分类器	识别状态编号									
SVM	8	10	3	11	1	12	2	9	7	2
	4	6	10	11	1	2	7	3	1	3
KNN	8	10	4	11	2	11	2	9	6	2
	2	7	10	8	6	2	6	4	2	4
随机森林	8	10	3	11	1	11	2	9	7	5
	4	6	10	9	6	2	7	3	1	4
BP神经网络 (85%)	4	10	4	3	4	6	4	3	4	4
	4	4	11	8	4	4	4	4	4	4

综上结果，BP神经网络的分类结果并不稳定，随着分类准确率的不同而不同，并不具有参考价值，故我们融合前三种分类器的识别结果，得到unknow数据集的状态类别如表4所示。

表 4. 未知状态识别结果

待测样本	状态类别	待测样本	状态类别	待测样本	状态类别	待测样本	状态类别
Unknow1	8	Unknow6	11	Unknow11	4	Unknow16	2
Unknow2	10	Unknow7	2	Unknow12	6	Unknow17	7
Unknow3	3	Unknow8	9	Unknow13	10	Unknow18	3
Unknow4	11	Unknow9	7	Unknow14	9	Unknow19	1
Unknow5	1	Unknow10	2	Unknow15	6	Unknow20	4

状态类别: 1. walking-forward 2. walking-left 3. walking-right 4. walking-upstairs 5. walking-downstairs 6. run 7. jump 8. Sitting 9. Standing 10. Sleeping 11. elevator-up 12. elevator-down

4. 总结

本文基于美国南加州大学的人体动作数据库 USC-HAD 中 14 名受试者 12 种运动状态的惯性传感器数据,采用巴特沃斯低通滤波器对原始信号进行预处理,消除高频噪声抑制干扰,再提取和筛选区分性好的统计量和物理量来刻画不同的运动特征,建立人身体主要部位在 12 种运动状态下的模型,最后,采用支持向量机、随机森林多种方法对训练集数据进行训练并分类识别测试集数据的状态类型,给出识别准确率,在此基础上,识别未知类别的运动状态。另外,本文特征模型的表示能力和区分能力较好,能够描述不同运动状态的差异,采用三种分类模型旨在选择一个最优的分类器,同时也是测试结果的相互检验。然而,模型的分类效果只能达到 80%左右,但从准确率上来说,还有待于改进和提高。

- 1) 获取更多的特征。在高维的特征空间进行特征选择,得到更有代表性和区分度的特征,例如除时域特征提取外,还可采用频域特征提取,比如 FFT 系数,频域熵等特征。
- 2) 获取数据方面,本文中使用的 USC-HAD 数据库,传感器位置固定,而有的动作在右大腿处的变化较为相似,因此,可以选择不同的佩戴部位,综合各部位得到的数据,可以保证更高的识别准确率。
- 3) 在预处理过程中,为避免一些错误数据的干扰,可事先剔除“野点”,通过设置阈值,用原数据减去做出的平滑曲线估计,若相减后的值大于阈值,则原始点可视为野点,进行剔除。
- 4) 本文的研究是对离线数据进行分析处理,后面可以将离线改为在线,完成实时的人体动作识别,这将会有更大的实际意义。
- 5) 将动作识别和生理参数监测结合,识别动作的同时进行生理信号的监测,可用于保障特殊人群的健康需求。
- 6) 运动状态数据的应用可以扩展到根据运动状态识别具体的行为。